



Dokumentace k projektu

Implementace překladače imperativního jazyka IFJ20

Tým 126, varianta II

Řešitelé:

Julie Gyselová (xgysel00)	25 %
Adrián Kálazi (xkalaz00)	25 %
Kevin Lackó (xlacko08)	25 %
Juraj Hrdlica (xhrdli14)	25 %

Rozšíření:

BASE
UNARY
BOOLTHEN

Úvod	3
Návrh	3
Lexikální analýza	3
Syntaktická analýza	3
Syntaktická analýza	3
Precedenční syntaktická analýza	4
Gramatická pravidla pro analýzu výrazů	4
Sémantická analýza	4
Generování IFJcode20	4
Použité datové struktury	5
Jednosměrně vázaný seznam	5
Tabulka symbolů	5
Tabulka s rozptýlenými položkami	5
Implementace	6
Způsob práce v týmu	6
Rozdělení práce v týmu	6
Použité zdroje	6
Konečný automat	7
Precedenční tabulka	8
Gramatika	9
LL-gramatika	9
LL-tabulka	11

Úvod

Tato dokumentace popisuje vývoj překladače pro jazyk IFJ20, který je podmnožinou jazyka Go. Vybrali jsme si variantu zadání II, podle které jsme tabulku symbolů implementovali pomocí tabulky s rozptýlenými položkami.

Návrh

Lexikální analýza

První částí projektu, která byla implementována, je scanner, který provádí lexikální analýzu. Podle konečného automatu, který jsme na začátku navrhli, jsme v modulech *scanner* a *scanner_states* implementovali scanner, který načítá znaky ze standardního vstupu a převádí je na tokeny (struktura), které ukládá do jednosměrně vázaného seznamu.

Zvlášť byl řešen případ identifikátorů a klíčových slov. Protože konečný automat neumožňuje rozlišení těchto dvou případů, vždy nejprve ověřujeme, že načtená sekvence znaků neodpovídá některému z klíčových slov, než vrátíme token označující identifikátor.

Pokud scanner narazí na posloupnost znaků, která neodpovídá žádnému tokenu, celý program končí s příznakem lexikální chyby.

Syntaktická analýza

Syntaktická analýza

Syntaktická analýza je prováděna v modulech *parser* a *rules* metodou rekurzivního sestupu ve dvou průchodech. V prvním průchodu se ukládají a kontrolují pouze hlavičky funkcí a ve druhém průchodu se kontroluje celý program.

Gramatika sestavená podle specifikace jazyka IFJ20, podle které jsme náš parser implementovali, není typu LL(1), který by byl ideální. Ve dvou případech je potřeba znát dva tokeny, aby bylo možné rozhodnout, které pravidlo bude použito. Ačkoliv by pravděpodobně bylo možné sestavit gramatiku tak, aby byla typu LL(1), v této dokumentaci přikládáme gramatiku a LL-tabulku, které odpovídají naší implementaci. Pravidla (31-33, 49-50), u kterých je potřeba znát dva tokeny místo jednoho, jsou v gramatice i v LL-tabulce zvýrazněná.

Precedenční syntaktická analýza

Pro zpracování výrazů je použita metoda syntaktické analýzy zdola nahoru pomocí precedenční tabulky.

Funkce *parse_expr* postupně načítá tokeny do zásobníku, určuje jejich typ a pomocí tabulky určuje vztah mezi prvním nezpracovaným tokenem na vrcholu zásobníku a tokenem na vstupu.

Pokud tabulka určí, že může být použito některé z pravidel, volá se funkce *reduce*, která zjišťuje které pravidlo se použije. Pokud žádné pravidlo neodpovídá tokenům na vrcholu zásobníku, syntaktická analýza končí s příznakem syntaktické chyby.

Gramatická pravidla pro analýzu výrazů

- | | |
|---|-----------------------------------|
| 1. $E \rightarrow (E)$ | 6. $E \rightarrow E == E, E != E$ |
| 2. $E \rightarrow +E, -E, !E$ | 7. $E \rightarrow E \&\& E$ |
| 3. $E \rightarrow E * E, E / E$ | 8. $E \rightarrow E \parallel E$ |
| 4. $E \rightarrow E + E, E - E$ | 9. $E \rightarrow i$ |
| 5. $E \rightarrow E < E, E <= E, E > E, E >= E$ | |

Sémantická analýza

Sémantická analýza je prováděna zároveň se syntaktickou analýzou podle sémantických pravidel jazyka IFJ20. Na příslušných místech v parseru jsou prováděny kontroly - zda použité funkce a proměnné jsou definované, zda souhlasí datové typy a počty proměnných a výrazů, které do nich jsou přiřazovány, zda nedochází k dělení nulou a zda návratové hodnoty funkce odpovídají její hlavičce.

Při zjištění sémantické chyby končí program s odpovídající návratovou hodnotou, a navíc na standardní chybový výstup vypisuje chybovou zprávu s podrobnostmi o chybě. Chybové hlášky byly inspirovány Go překladačem^[3].

Generování IFJcode20

Generování výstupního kódu IFJcode20 je poslední fází našeho překladače. Generátor se skládá z předpřipravených funkcí v modulu *generator*, které se volají z odpovídajících míst v parseru.

Na začátku generátor vždy vypíše definice vestavěných funkcí jazyka IFJ20 a zavolá funkci *main*. Za zmínku také stojí to, že příkaz *CREATEFRAME* je použit vždy pouze na

začátku funkce a rozlišování proměnných napříč různými rámci je řešeno pomocí unikátních názvů.

Použité datové struktury

Jednosměrně vázaný seznam

Jednosměrně vázaný seznam je struktura, kterou jsme v projektu hojně využívali. Implementovali jsme jej proto velmi obecným způsobem, abychom jej mohli využít na více místech (např. v sémantické analýze při hlídání návratových typů funkcí).

Tabulka symbolů

Abychom správně mohli řešit rámce, je naše tabulka symbolů ve skutečnosti implementovaná jako zásobník tabulek s rozptýlenými prvky. V těchto tabulkách ukládáme různé informace o proměnných (názvy, datové typy a hodnoty) a o funkcích (názvy, seznam vstupních argumentů a seznam návratových datových typů).

Tabulka s rozptýlenými položkami

Implementace tabulky s rozptýlenými položkami byla inspirována druhým projektem předmětu IJC^[1]. Jako hashovací funkci jsme použili algoritmus FNV-1a^[2], který se nám zdál nejoptimálnější.

Implementace

Způsob práce v týmu

Překladač jsme postupně vyvíjeli v průběhu října, listopadu a prosince. Při práci jsme k verzování používali systém Git a k vytváření testů, které jsme všichni psali k různým částem projektu, jsme využili framework Googletest. Komunikovali jsme výhradně přes platformu Discord a vzhledem k aktuální situaci, všechny naše schůzky probíhaly online.

Rozdělení práce v týmu

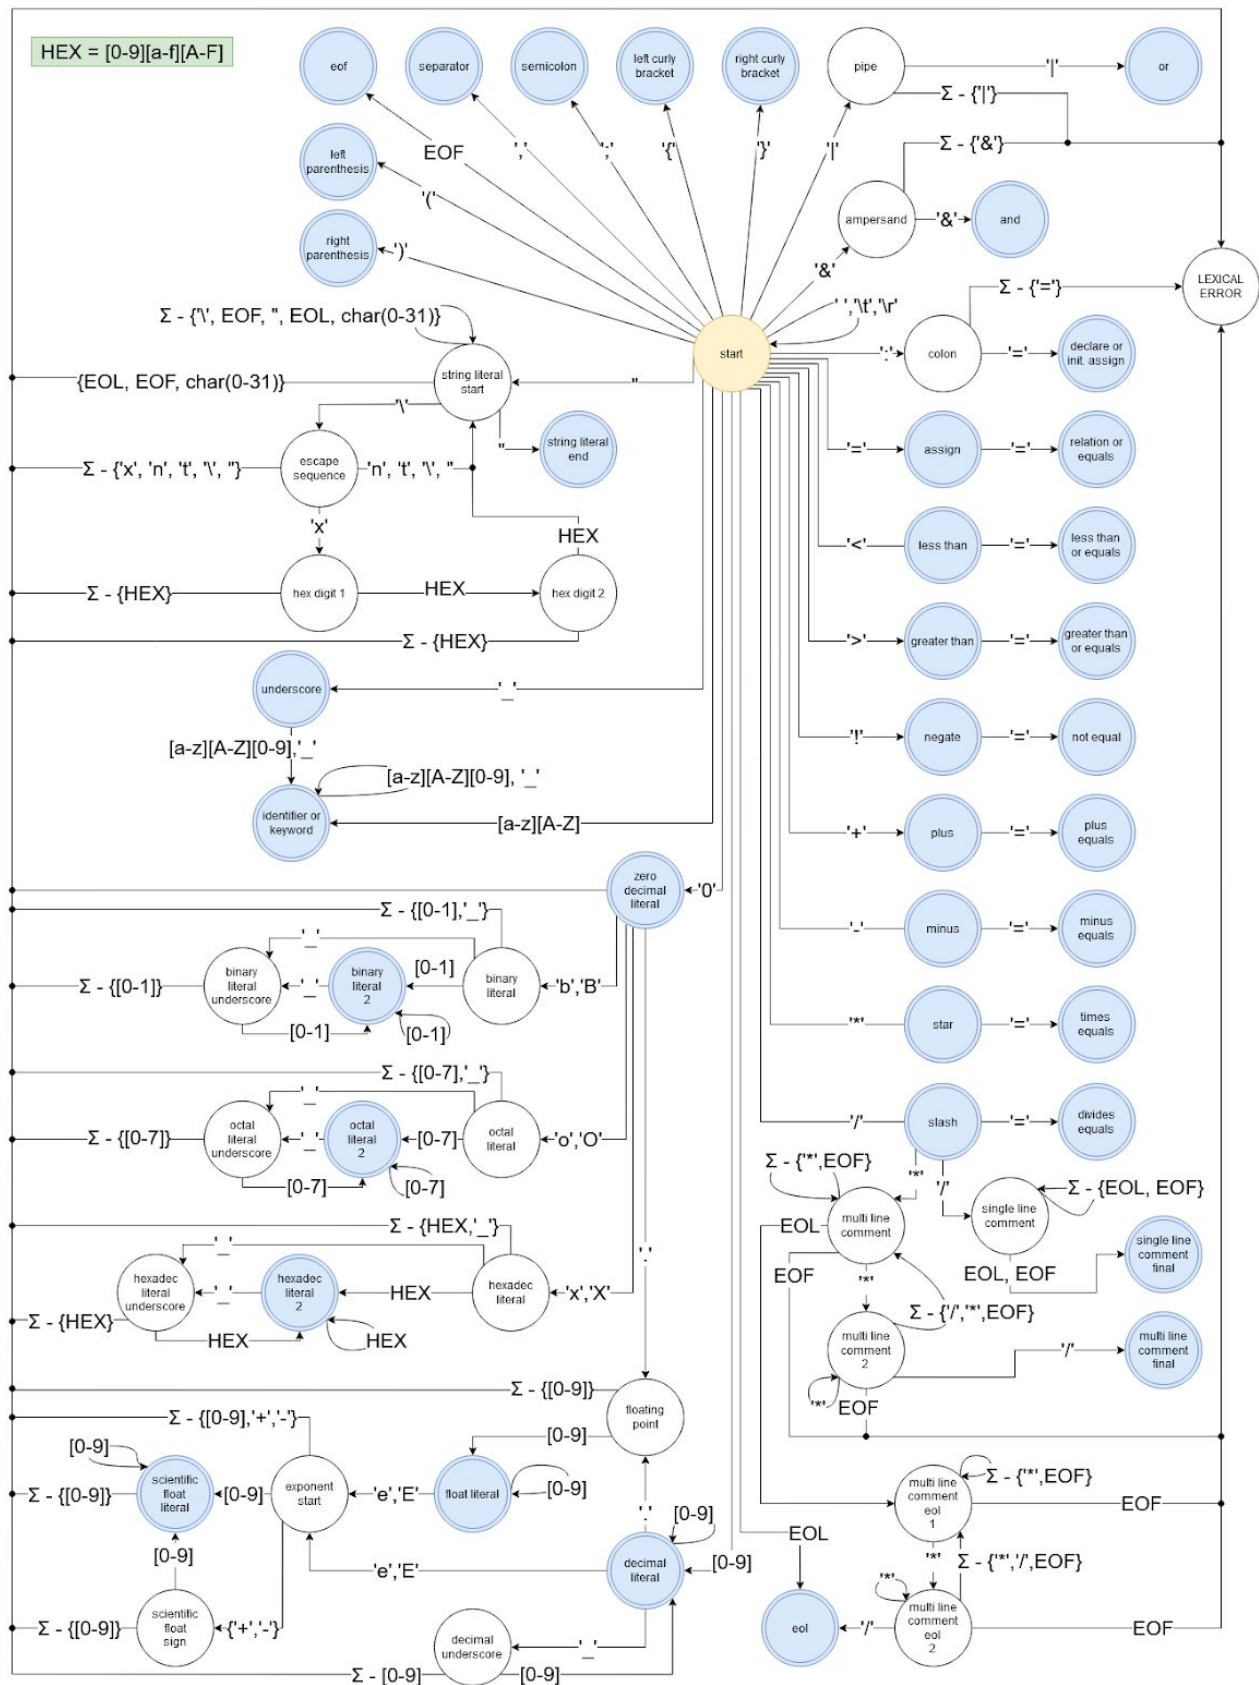
- Julie Gyselová (25 %)
 - Návrh gramatiky
 - Syntaktická analýza
 - Analýza výrazů
 - Dokumentace
- Adrián Kálazi (25 %)
 - Build setup (Make, CMake, CI)
 - Lexikální analýza (implementace přechodu mezi stavy)
 - Dynamické pole znaků
 - Generování výstupního kódu
- Kevin Lackó (25 %)
 - Návrh gramatiky
 - Syntaktická analýza
 - Sémantická analýza
 - Tabulka symbolů
- Juraj Hrdlica (25 %)
 - Návrh konečného automatu
 - Lexikální analýza

Použité zdroje

- [1] <https://www.fit.vutbr.cz/study/courses/IJC/public/DU2.html>
- [2] <http://www.isthe.com/chongo/tech/comp/fnv/index.html#FNV-1a>
- [3] <https://play.golang.org>

Konečný automat

Scanner Finite State Machine



Precedenční tabulka

	()	un	* /	+ -	< <= > >=	== !=	&&		i	\$
(<	=	<	<	<	<	?	<	<	<	
)		>	>	>	>	>	>	>	>		>
un	<	<	<	>	>	>	>	>	>	<	>
*/ + -	<	>	<	>	>	>	>	>	>	<	>
< <= > >=	<	>	<	<	<	>	>	>	>	<	>
== !=	<	?	<	<	<	<	>	>	>	<	>
&&	<	>	<	<	<	<	<	>	>	<	>
	<	>	<	<	<	<	<	<	>	<	>
i		>		>	>	>	>	>	>		>
\$	<		<	<	<	<	<	<	<	<	

Gramatika

LL-gramatika

1. Program -> Eol_opt_n Prolog Eol_opt_n Functions Eol_opt_n eof
2. Prolog -> *package main eol*
3. Functions -> Function Eol_opt_n Functions
4. Functions -> *eps*
5. Function -> *func id* Param_list Returntype_list *l_curly eol*
Eol_opt_n Statements *r_curly*
6. Param_list -> *l_parenthesis* Params *r_parenthesis*
7. Params -> Param Param_n
8. Params -> *eps* .
9. Param_n -> *comma* Eol_opt_n Param Param_n
10. Param_n -> *eps*
11. Param -> *id* Paramtype
12. Paramtype -> *int*
13. Paramtype -> *float64*
14. Paramtype -> *string*
15. Paramtype -> *bool*
16. Returntype_list -> *l_parenthesis* Returntypes *r_parenthesis*
17. Returntype_list -> *eps*
18. Returntypes -> Returntype Returntype_n
19. Returntypes -> *eps*
20. Returntype_n -> *comma* Eol_opt_n Returntype Returntype_n
21. Returntype_n -> *eps*
22. Returntype -> *int*
23. Returntype -> *float64*
24. Returntype -> *string*
25. Returntype -> *bool*
26. Statements -> Def_ass_call Eol_opt_n Statements
27. Statements -> Conditionals Eol_opt_n Statements
28. Statements -> Iterative Eol_opt_n Statements
29. Statements -> Return Eol_opt_n Statements
30. Statements -> *eps*
31. Def_ass_call -> Var_define *eol*
32. Def_ass_call -> Function_call *eol*
33. Def_ass_call -> Assignment *eol*
34. Var_define_opt -> Var_define
35. Var_define_opt -> *eps*
36. Var_define -> *id define_op* Expression
37. Conditionals -> Conditional Conditional_n *eol*
38. Conditional_n -> *else* Else
39. Conditional_n -> *eps* .
40. Else -> Conditional Conditional_n
41. Else -> *l_curly eol* Eol_opt_n Statements *r_curly* .
42. Conditional -> *if* Expression *l_curly eol*
43. Conditional -> Eol_opt_n Statements *r_curly*
44. Iterative -> *for* Var_define_opt *semicolon* Expression *semicolon*
45. Iterative -> Assignment_opt *l_curly eol*
46. Iterative -> Eol_opt_n Statements *r_curly eol*
47. Assignment_opt -> Assignment
48. Assignment_opt -> *eps*
49. Assignment -> Assignment_list
50. Assignment -> Id Assign_op Exprs_funcall
51. Assignment_list -> Ids assign Eol_opt_n Exprs_funcall

```

52. Ids -> Id Id_n
53. Id_n ->      comma Id Id_n
54. Id_n -> eps
55. Id -> id
56. Id -> underscore
57. Assign_op -> plus_assign Eol_opt_n
58. Assign_op -> minus_assign Eol_opt_n
59. Assign_op -> multiply_assign Eol_opt_n
60. Assign_op -> divide_assign Eol_opt_n
61. Assign_op -> assign Eol_opt_n
62. Exprs_funcall -> Expression
63. Exprs_funcall -> Function_call
64. Function_call -> id l_parenthesis Eol_opt_n Arguments
                    r_parenthesis
65. Arguments -> Argument Argument_n
66. Arguments -> eps
67. Argument_n -> comma Eol_opt_n Argument Argument_n
68. Argument_n -> eps
69. Argument -> id
70. Argument -> Literal
71. Return -> return Expressions_opt eol
72. Expressions_opt -> Expressions
73. Expressions_opt -> eps
74. Expressions -> expression Expression_n
75. Expression_n -> comma expression Expression_n
76. Expression_n -> eps
77. Literal -> int_lit
78. Literal -> float_lit
79. Literal -> string_lit
80. Literal -> true
81. Literal -> false
82. Eol_opt_n -> eol Eol_opt_n
83. Eol_opt_n -> eps

```

LL tabulka

[illegible]